

2.4 节内容的问题

(1) 对于回归问题的线性回归模型，为什么损失函数选择为最小平方损失（预测值与真实值之间误差的均方误差）？优化目标是寻找合适的参数 $\mathbf{w}$ 最小化均方误差（MMSE），其背后的数学原理是什么？请给出数学推导过程？一般，可记最优模型参数为 $\mathbf{w}^*$ 或 $\mathbf{w}_o$ 。

(2) 对于线性回归模型，其损失函数采用均方误差 $\frac{1}{|D|} \sum_{(x,y) \in D} (f_{\mathbf{w}}(x) - y)^2$ ，即

$$\begin{aligned} \text{TrainLoss}(\mathbf{w}) &= \frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} (f_{\mathbf{w}}(x) - y)^2 \\ &= \frac{1}{|D_{\text{train}}|} (\mathbf{y} - \Phi \mathbf{w})^T (\mathbf{y} - \Phi \mathbf{w}) \\ &= \frac{1}{|D_{\text{train}}|} \text{RSS}(\mathbf{w}) \end{aligned}$$

基于矩阵运算表示，给出残差平方和 $\text{RSS}(\mathbf{w})$ 对模型参数 $\mathbf{w}$ 的梯度 $\nabla_{\mathbf{w}} \text{RSS}(\mathbf{w})$ 的理论计算的推导过程，以及训练损失函数 $\text{TrainLoss}(\mathbf{w})$ 对模型参数 $\mathbf{w}$ 的梯度 $\nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w})$ 的表示，并给出模型参数最优解的闭式解表达式。对下面 PPT 里的不妥之处，请指出。

优化例子：线性回归

$$\begin{aligned} \arg \min_{\mathbf{w}} \text{TrainLoss}(\mathbf{w}) &= \arg \min_{\mathbf{w}} \frac{1}{|D_{\text{train}}|} (\mathbf{y} - \Phi \mathbf{w})^T (\mathbf{y} - \Phi \mathbf{w}) \\ &= \arg \min_{\mathbf{w}} \underbrace{(\mathbf{y} - \Phi \mathbf{w})^T (\mathbf{y} - \Phi \mathbf{w})}_{\substack{\text{RSS}(\mathbf{w}) \\ \text{residual sum of squares} \\ \text{残差平方和}}} \end{aligned}$$

$$\begin{aligned} \text{TrainLoss}(\mathbf{w}) &= \frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} (f(x) - y)^2 \\ &= \frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} (\mathbf{w} \cdot \phi(x) - y)^2 \\ &= \frac{1}{|D_{\text{train}}|} (\mathbf{y} - \Phi \mathbf{w})^T (\mathbf{y} - \Phi \mathbf{w}) \end{aligned}$$

$$\begin{aligned} \nabla_{\mathbf{w}} \text{RSS}(\mathbf{w}) &= \nabla_{\mathbf{w}} (\mathbf{y} - \Phi \mathbf{w})^T (\mathbf{y} - \Phi \mathbf{w}) \\ &= -2\Phi^T (\mathbf{y} - \Phi \mathbf{w}) \end{aligned}$$

推导示例

$$\nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w}) = \frac{2}{|D_{\text{train}}|} \Phi^T (\mathbf{y} - \Phi \mathbf{w})$$

方法一：梯度设置为0

$$\text{令 } \nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w}) = \frac{2}{|D_{\text{train}}|} \Phi^T (\mathbf{y} - \Phi \mathbf{w}) = 0$$

(对于凸函数) 我们得到参数向量 $\mathbf{w}$ 的闭式解

$$\mathbf{w}^* = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y}$$

all observations (# = N)

$\Phi: N \times d$

- Need to be invertible (须满足可逆条件)
- Complexity of inverse (矩阵求逆计算复杂度)

(3) 实际应用中一般不选择闭式解，而是采用基于梯度下降的迭代优化算法寻找模型参数

最优解 $\mathbf{w}^*$ ，为什么？写出最优模型参数 $\mathbf{w}^*$ 迭代计算的伪代码。

(4) 给出下面 PPT 页面里例子的模型参数迭代的详细计算过程。按规范的矩阵和向量运算规则给出。PPT 里给出了前两步，请给出第 3 步和第 4 步的计算结果。

方法2：梯度下降

training data $\mathcal{D}_{\text{train}}$

x	y
1	1
2	3
4	3

$$\nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w}) = \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y) \in \mathcal{D}_{\text{train}}} 2(\mathbf{w} \cdot \phi(x) - y)\phi(x)$$

梯度更新: $\mathbf{w} \leftarrow \mathbf{w} - 0.1 \nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w})$

t	$\nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w})$	$\mathbf{w}$
		$[0, 0]$
1	$\frac{1}{3} (2([0, 0] \cdot [1, 1] - 1)[1, 1] + 2([0, 0] \cdot [1, 2] - 3)[1, 2] + 2([0, 0] \cdot [1, 4] - 3)[1, 4])$ $= [-4.67, -12.67]$	$[0.47, 1.27]$
2	$\frac{1}{3} (2([0.47, 1.27] \cdot [1, 1] - 1)[1, 1] + 2([0.47, 1.27] \cdot [1, 2] - 3)[1, 2] + 2([0.47, 1.27] \cdot [1, 4] - 3)[1, 4])$ $= [2.18, 7.24]$	$[0.25, 0.54]$
...	...	...
200	$\frac{1}{3} (2([1, 0.57] \cdot [1, 1] - 1)[1, 1] + 2([1, 0.57] \cdot [1, 2] - 3)[1, 2] + 2([1, 0.57] \cdot [1, 4] - 3)[1, 4])$ $= [0, 0]$	$[1, 0.57]$

Pytorch或者TensorFlow等深度学习框架集成了自动求导的功能
MATLAB演算示例

(5) 以上内容，包括 PPT 页面，对于 $\text{TrainLoss}(\mathbf{w})$ 的表示似乎有两种不同的形式：

$$\begin{aligned}
 \text{TrainLoss}(\mathbf{w}) &= \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y) \in \mathcal{D}_{\text{train}}} (f(x) - y)^2 \\
 &= \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y) \in \mathcal{D}_{\text{train}}} (\mathbf{w} \cdot \phi(x) - y)^2 \\
 &= \frac{1}{|\mathcal{D}_{\text{train}}|} (\mathbf{y} - \Phi \mathbf{w})^\top (\mathbf{y} - \Phi \mathbf{w})
 \end{aligned}$$

区别是什么？有什么影响吗？